

**PROCÈS-VERBAL DE SOUTENANCE
D'UNE
HABILITATION À DIRIGER DES RECHERCHES**

Arrêté du 23 novembre 1988 relatif à l'habilitation à diriger des recherches

Monsieur Romain AZAÏS

Né le : 07/07/1987, à Béziers (FRANCE)

Nationalité : Française



Candidat à l'**Habilitation à Diriger des Recherches en Mathématiques**, (Section CNU n°26)

a présenté publiquement en soutenance une habilitation à diriger des recherches sur le thème suivant :

« Approches algorithmiques pour la statistique : processus déterministes par morceaux et arbres aléatoires »

Après délibération, le jury présidé par (Prénom - NOM) : Frank PICARD

et composé de :

Membres du jury		Signatures
Monsieur Julien CHIQUET	Directeur de recherche	
Madame Benoîte DE SAPORTA	Professeur des universités	
Monsieur Marc TOMMASI	Professeur des universités	
Madame Anne GEGOUT	Professeur des universités	
Monsieur Jean-Baptiste DURAND	Maître de conférences - HDR	
Monsieur Franck PICARD	Directeur de recherche	
Monsieur Christophe GODIN	Directeur de recherche	

Article 7 de l'arrêté du 23 novembre 1988 modifié par l'arrêté du 13 juillet 1995 :

L'admission ou l'ajournement est prononcé après délibération du jury. Le président du jury établit et signe le rapport de soutenance qui est contresigné par l'ensemble des membres du jury. Le rapport de soutenance est communiqué au candidat.

déclare le candidat :

☒ ADMIS à l'Habilitation à Diriger des Recherches

☐ AJOURNÉ

À Lyon, le 02 décembre 2022.

1^{er} rapporteur (NOM et prénom) : Julien Chiquet

2^{ème} rapporteur (NOM et prénom) : Marc Tommasi

3^{ème} rapporteur (NOM et prénom) : Benoîte de Saporta



de l'HABILITATION À DIRIGER DES RECHERCHES en Mathématiques à l'ENS de Lyon

de Monsieur Romain AZAÏS,

le 02 décembre 2022

sur le thème suivant :

« Approches algorithmiques pour la statistique : processus déterministes par morceaux et arbres aléatoires »

Arrêté du 23 novembre 1988 relatif à l'Habilitation à Diriger des Recherches

[Le président du jury, après avoir recueilli l'avis des membres du jury, établit un rapport qui est **contresigné** par l'ensemble des membres du jury. Le Rapport de soutenance est communiqué au candidat.]

... Romain AZAÏS a présenté une synthèse de ses travaux de recherche au cours d'un exposé pédagogique mettant en valeur ses compétences dans différents domaines de math. appliquées, comme la statistique les processus, la combinatoire et l'apprentissage.

Le jury a été impressionné par le très large spectre et la profondeur de ses résultats et contributions de R. AZAÏS, faisant de lui un chercheur de référence dans les domaines qu'il aborde.





Le jury a également apprécié le talent de R. AZAÏS à motiver les choix de ses directions scientifiques, ainsi qu'à expliquer les points techniques spécifiques aux sujets qu'il étudie.

Son enthousiasme communicatif lui a déjà permis de former des doctorants et jeunes chercheurs et de porter des directions de recherche pluridisciplinaires innovantes et prometteuses au sein de son équipe de recherche.



..... Au vu de l'ensemble de ses qualités, le jury
 propose et recommande que M. François MORAINE
 excellent directeur de Recherche ou professeur
 lui débre l'habilitation à diriger
 les recherches.....

Signatures de tous les membres du jury

Membres du Jury	Signatures
Monsieur Julien CHIQUET	
Madame Benoîte DE SAPORTA	
Monsieur Marc TOMMASI	
Madame Anne GEGOUT	
Monsieur Jean-Baptiste DURAND	
Monsieur Franck PICARD	
Monsieur Christophe GODIN	



Rapport de soutenance

version numérique

Romain Azaïs a présenté une synthèse de ses travaux de recherche au cours d'un exposé pédagogique mettant en valeur ses compétences dans différents domaines des mathématiques appliquées comme la statistique des processus, la combinatoire et l'apprentissage.

Le jury a été impressionné par le très large spectre et la profondeur des résultats et contributions de M. Azaïs, faisant de lui un chercheur de référence dans les domaines qu'il investit.

Le jury a grandement apprécié le talent de Romain Azaïs à motiver les choix de ses directions scientifiques, ainsi qu'à expliquer les points techniques spécifiques aux objets qu'il étudie.

Son enthousiasme communicatif lui a déjà permis de former des doctorants et jeunes chercheurs et de porter des directions de recherche pluridisciplinaires innovantes et prometteuses au sein de son équipe de recherche.

Au vu de l'ensemble de ses qualités, le jury unanime est convaincu que M. Azaïs sera un excellent directeur de recherche ou professeur et lui délivre l'habilitation à diriger des recherches.

Julien CHIQUET
Directeur de recherche INRAE, HDR
MIA Paris-Saclay – Université Paris-Saclay/AgroParisTech/INRAE
web: <https://jchiquet.github.io>
mel: julien.chiquet@inrae.fr

Paris, 1^{er} novembre 2022

[Objet]

Rapport sur le mémoire d'HDR de Romain AZAÏS intitulé « *Approches Algorithmiques pour la statistique : processus déterministes par morceaux et arbres aléatoires* »

Romain AZAÏS présente dans son mémoire d'habilitation ses travaux de recherche en statistique les plus emblématiques menés depuis son doctorat, soutenu dans le courant de l'été 2013. Ces travaux portent essentiellement sur deux objets emblématiques – éponymes au manuscrit d'habilitation – rencontrés dans divers champs de la statistique : les processus markoviens déterministes par morceaux (ou *PDMP*, en référence à l'acronyme anglais), et les arbres aléatoires.

De part la nature même de ces objets, les contributions de Romain AZAÏS sont à la croisée de plusieurs chemins : la statistique inférentielle, les processus aléatoires, l'apprentissage, l'algorithmie et l'informatique théorique. Cette pluralité disciplinaire n'est jamais au détriment du niveau d'expertise et de la qualité des contributions du candidat, manifestement de très haut niveau. Romain AZAÏS réussit le tour de force d'accompagner ses contributions théoriques et méthodologiques d'algorithmes et d'implémentations d'excellente facture, sans galvauder les applications de la statistique et l'utilisation de ces concepts dans un contexte d'analyse de données et de modélisation de phénomènes réels. Un tel profil – trop rare – permet au candidat d'adopter des points de vue divers et un horizon élargi. La conséquence est un manuscrit riche, ponctué d'analyses et d'intuitions distillées avec pertinence tant pour accompagner les résultats théoriques que pour justifier des choix de modélisation liés à la nature des données ou au coût computationnel des approches envisagées.

Le manuscrit est volontairement court : il compte environ soixante-dix pages rédigées en français et très agréablement présentées. Un bref prologue donne les objectifs avérés du rapport : dresser un panorama des résultats les plus saillants des travaux menés depuis la thèse, montrer leur limite, mais aussi – et surtout ? – de les mettre en perspective. Si le manuscrit s'appuie principalement sur 8 articles de référence publiés ou en phase de l'être, il couvre néanmoins très largement la bibliographie de Romain AZAÏS, qui compte déjà 24 articles de journaux et 2 pré-publications à ce jour. La présentation s'articule en quatre chapitres où le candidat fait le choix de ne pas intégrer de preuve ou d'expérience numérique. En somme, la relative brièveté du document est à mon avis un véritable atout pour permettre au lecteur de rentrer dans les contributions de Romain AZAÏS. Le

niveau de technicité et de détail adopté est très juste pour un rapport d’habilitation de mon point de vue. Il montre un bel esprit de synthèse, un certain talent pédagogique, un grand recul et un niveau d’expertise considérable sur les questions propres au manuscrit et sur le métier de chercheur en général. J’ai beaucoup apprécié cette démarche et le ton général adopté qui témoigne de l’enthousiasme manifeste du candidat lors de l’écriture.

Plus spécifiquement, le manuscrit est structuré autour des deux parties thématiques *PDPM* et *arbres*, chacune comptant deux chapitres :

- La première partie fournit des résultats importants d’estimation portant sur les PDMP : un chapitre est dédié à l’estimation des paramètres régissant la dynamique du processus (ici le taux de saut) à partir d’une unique trajectoire en temps long, dans un cadre volontairement général et sous hypothèse d’ergodicité. Un second chapitre s’intéresse non plus aux paramètres de la dynamique du PDMP lui-même mais à des quantités d’intérêt qui sont fonctions des trajectoires, et qui sont présentées à juste titre comme plus directement pertinentes dans un cadre applicatif. En particulier, la question du croisement d’un seuil est étudié en profondeur. Au long de cette partie, Romain AZAÏS fournit des résultats théoriques de convergence des estimateurs et des algorithmes qui pointent des problématiques numériques et questionnent les différents cadres d’étude vis-à-vis de la modélisation envisagée.
- La deuxième partie porte sur l’utilisation des arbres aléatoires comme outil de représentation des données. Le chapitre trois mène Romain AZAÏS vers des questions d’apprentissage statistique, ce qui semble finalement assez naturel au vu de son parcours sur les PDMP. Il étudie le comportement d’un noyau de convolution spécifique à ces données (noyau des sous arbres) dans un cadre de classification supervisée, et met en particulier en exergue les limitations liées à la forme exponentielle de la fonction de poids intervenant dans ce noyau. Enfin, le dernier chapitre regroupe des résultats d’inférence statistique dans le cadre des processus de Galton-Watson, définissant une loi de probabilités sur les arbres. Romain AZAÏS étudie deux versions de ces modèles issus du conditionnement par la taille ou par la hauteur des arbres générés.

Tout au long de ces chapitres, Romain AZAÏS a présenté des travaux très intéressants, témoignant d’une haute maîtrise technique (il est clairement un expert reconnu sur les PDMP), et d’intérêt pour la communauté des statisticien(ne)s dans son acception la plus large : théorie et inférence des processus, statistique computationnelle, apprentissage statistique mais aussi modélisation statistique et statistiques appliquées. Il a publié ses travaux dans d’excellentes revues de statistiques (*e.g. Scandinavian, Environmetric, JSPI*), d’apprentissage (*e.g. JMLR*), d’informatique (*e.g. IEEE Local Computer Network, Theoretical Computer Science*), avec des incursions dans des journaux à l’interface et de logiciels (*JOSS*). Le total de sa production scientifique est excellent, appuyé par des packages R et Python qui vont bien au delà de la simple illustration, comme on en voit souvent, et constituent de véritables boîtes à outils et contributions à part entière.

En plus d’être un chercheur reconnu, avec une carrière ponctuée d’expériences riches (post-doctorat, incursion dans la recherche opérationnelle en data science chez Sanofi), Romain Azaïs a déjà démontré qu’il savait encadrer des étudiants (en master, en post-doc et en thèse). En particulier, il semble avoir eu un rôle central dans l’encadrement de la thèse de Florian Ingels.

En conclusion, Romain Azaïs a démontré qu'il était un chercheur accompli, avec une grande maîtrise de sa thématique et une excellente culture en statistique et plus largement en mathématique et en informatique. Ses contributions sur les PDMP sont très abouties et en font un expert de tout premier plan sur cette question. Ses travaux sur les arbres démontrent d'une très grande maturité et son ouverture à l'apprentissage et une pleine réussite. Je suis réellement impressionné par ce début de carrière et enthousiaste à l'idée des futures contributions du candidat, dont les compétences croisées en statistiques, probabilités et apprentissage promettent d'être dynamisantes pour la communauté des statisticien(ne)s.

Pour toutes ces raisons, j'émet sans aucune retenue et avec enthousiasme un **avis très favorable** à la soutenance d'habilitation de Romain AZAÏS.

Julien Chiquet, le 1^{er} novembre 2022

A handwritten signature in black ink, appearing to read 'Julien Chiquet', with a long horizontal stroke extending to the right.

Rapport sur le dossier d'habilitation à diriger des recherches de ROMAIN AZAÏS

Approches algorithmiques pour la statistique : processus déterministes par morceaux et arbres aléatoires

BENOÎTE DE SAPORTA

Les travaux post-thèse de Romain Azaïs comprennent sur la période 2015-2022 14 articles publiés dans un large choix de très bonnes revues à comité de lecture ainsi que 2 preprints, 5 actes de conférences internationales, une direction d'ouvrage et un chapitre de livre, ainsi qu'une librairie python et deux librairies R. Ces travaux portent essentiellement sur l'inférence statistique avec une forte composante algorithmique dans deux cadres privilégiés : celui des processus de Markov déterministes par morceaux (PDMP) et celui des données à structure d'arbre.

Le manuscrit de synthèse est structuré en 4 chapitres précédés d'une brève grille de lecture. Chaque chapitre est consacré à la présentation et la mise en perspective de deux articles formant un tout cohérent et représentatif de l'ensemble des contributions du candidat dans les deux domaines étudiés. Les deux premiers chapitres concernent les PDMP, les deux derniers les arbres aléatoires.

Le premier chapitre est consacré à l'estimation de l'intensité d'un PDMP. Il commence par un rappel de la dynamique d'un PDMP : déterministe suivant un flot entre des sauts aléatoires dont les dates sont déterminées par l'intensité λ ou des sauts à la frontière de l'espace d'état, et les positions après-saut par un noyau markovien. Le cadre d'étude est ensuite défini. Il s'agit d'estimation non paramétrique de l'intensité d'un PDMP ergodique générique à partir de l'observation parfaite d'une seule trajectoire (durées inter-saut et positions après-saut) en temps long. Le premier estimateur, proposé pendant la thèse, repose sur l'approche de Nelson-Aalen pour estimer l'intensité $\tilde{\lambda}$ des durées inter-saut conditionnées aux positions courantes et après-saut du processus. La première alternative présentée dans ce chapitre consiste à décomposer $\tilde{\lambda}$ sur une base de fonctions L^2 (Fourier ou Legendre en pratique), estimer de façon empirique le noyau de saut du PDMP lorsque celui-ci est discret, et estimer par plug-in via l'estimateur de Nelson-Aalen les coefficients de la décomposition. On obtient alors un estimateur convergent de λ ainsi qu'un test de nullité des coefficients. La deuxième alternative pour des PDMP à valeurs dans $\mathbb{R}^d$ à noyau de saut quelconque propose des estimateurs à noyau permettant de reconstruire la densité et la fonction de survie des durées inter-saut conditionnées à la position courante. La convergence et la normalité asymptotiques sont établies, ainsi qu'une méthodologie d'optimisation des paramètres et des fenêtres de lissage. Le chapitre se conclut par une discussion et des perspectives d'explorations complémentaires. Les travaux de Romain Azaïs autour de l'estimation de l'intensité des PDMPs, problème notablement difficile, sont les tous premiers et les seuls abordant ce problème de façon générique sans se restreindre à des sous-classe très spécifiques de processus. Il s'agit d'une contribution majeure à la compréhension des nombreuses originalités et difficultés de ces processus.

Le deuxième chapitre s'intéresse à l'estimation de quantités liées à des problèmes de passage pour les PDMP. Comme les PDMP sont des processus à saut, les franchissements de seuils peuvent survenir lors d'un saut (première partie) soit le long du flot (deuxième partie). Dans une première partie, on considère un processus de croissance fragmentation en dimension 1 modélisant un problème d'assurance. La croissance est exponentielle si la valeur du processus dépasse 1, nulle sinon, la fragmentation quelconque de loi G et l'intensité des sauts λ constante. On s'intéresse à l'estimation semi-paramétrique de la probabilité d'absorption et de la loi du temps d'atteinte de l'intervalle absorbant $[0, 1]$. A nouveau, les observations disponibles sont les durées inter-saut et positions après-saut sur une seule trajectoire. Dans une deuxième partie, on se place en dimension d , et on s'intéresse à l'estimation du nombre moyens de franchissements continus (par opposition à des franchissements lors d'un saut) d'une hypersurface. On suppose cette fois-ci que les observations disponibles sont la position du PDMP sur une grille de temps qui ne comporte pas nécessairement les temps de saut, pour plusieurs trajectoires indépendantes, ce qui correspond par exemple à un cadre applicatif de type bio-logging. Dans les deux cas de figure étudiés, l'idée originale et élégante de Romain Azaïs est d'obtenir et d'exploiter une expression analytique des quantités à estimer, soit explicite, soit sous forme de solution d'équation fonctionnelle ou réursive, et faisant intervenir différents paramètres du PDMP plus faciles à estimer directement (par maximum de vraisemblance pour λ , Parzen-Rosenblatt pour G dans la première partie, ou estimateur à noyau de la densité du PDMP à chaque date d'observation dans la deuxième partie). Les estimateurs des quantités d'intérêt sont alors construits par plug-in dans des approximations numériques des fonctionnelles ou solutions des équations. Leur convergence est établie par une étude fine des propagations d'erreurs lors des différentes étapes. Dans ces travaux, Romain Azaïs démontre la pertinence et le fort potentiel d'approches combinant équations fonctionnelles, estimation statistique et approximations numériques pour estimer diverses quantités d'intérêt des PDMP, et ouvre la voie vers d'autres combinaisons judicieuses possibles de ces différents outils.

Le troisième chapitre présente les travaux menés lors du co-encadrement (avec Christophe Godin) de la thèse de Florian Ingels. Il s'agit de classification supervisée de données structurées en arbres, et plus précisément de quantifier la similarité de deux arbres à partir de leurs sous-arbres ou de sous-forêts dans un souci d'interprétabilité des classifieurs. N'étant pas spécialiste de ce domaine, je n'en ferai pas d'analyse poussée. Je tiens particulièrement à souligner la très grande qualité de la rédaction du document de synthèse dont la lecture est particulièrement fluide et agréable et qui rend parfaitement claires et accessibles aux non spécialistes les questions posées, leurs enjeux, les difficultés rencontrées ainsi que les stratégies entreprises pour les traiter.

Le quatrième et dernier chapitre revient à la statistique des processus combinée avec une structure des données sous forme d'arbre. Il y est question d'inférence dans des arbres de Galton-Watson (à temps discret) conditionnés par la taille (le nombre de noeuds) ou par la survie (en terme de nombre de générations). Le premier cas fait office de cas-test pour la pertinence des approches fonctionnelles pour les données structurées en arbre. En effet, l'approche repose sur la convergence en loi d'un processus de type contour vers une excursion brownienne. Dans ce contexte, seule la variance de la loi reproduction est identifiable. Différents estimateurs à base de l'observation d'un ou plusieurs arbres sont proposés, et leurs propriétés asymptotiques établies, même si dans un cadre sans données manquantes ou bruitées, l'estimateur de la variance empirique converge bien vers la quantité voulue. Dans le deuxième cadre d'étude d'arbres conditionnés à survivre, la solution proposée passe par la reconstruction de l'épine dorsale de l'arbre dont la loi est une version biaisée de la loi de reproduction, ou de façon analogue l'identification du type de chaque noeud dans un arbre de Galton Watson à deux types cachés. A nouveau, des

estimateurs avec de bonnes propriétés asymptotiques sont construits et étudiés pour la loi de reproduction, le biais de la loi de reproduction de l'épine dorsale ainsi que pour l'épine dorsale elle-même. Comme les trois précédents, ce chapitre se conclut par une discussion et des perspectives d'explorations complémentaires, mettant particulièrement en valeur la profondeur de la compréhension des problématiques abordées, sans pour autant esquiver les limites actuelles des approches proposées et les verrous à défier pour les contourner.

Les travaux de Romain Azaïs en statistique mathématique et algorithmique couvrent un large spectre d'objets mathématiques allant des processus à temps et espaces continus aux arbres discrets et statiques en passant par quelques combinaisons des deux. Les outils utilisés sont particulièrement variés et intéressants. Les résultats obtenus sont souvent raffinés et pionniers dans des domaines difficiles et encore peu explorés, et contribuent significativement à la compréhension des objets mathématiques sous-jacents tout en étant applicables et appliqués sur données réelles. Dans toutes ses excursions, un point saillant de la démarche de Romain Azaïs est le souci constant de combiner fondations théoriques si possible générales, intuition, et efficacité algorithmique, chacun de ces aspects éclairant et guidant les autres. La richesse et la pertinence des perspectives concluant chacun des chapitres du manuscrit témoigne d'une grande maturité et d'un recul certain sur les domaines étudiés. Enfin, Romain Azaïs s'est également beaucoup investi dans le co-encadrement de deux thèses soutenues, ainsi que dans le développement de packages R et Python.

Je donne donc un avis extrêmement favorable à la soutenance de l'habilitation à diriger des recherches de Romain Azaïs.

Montpellier, le 1er novembre 2022

Benoîte de Saporta
Professeure des Universités
Université de Montpellier



Rapport concernant le mémoire d'habilitation
« Approches algorithmiques pour la statistique :
processus déterministes par morceaux et arbres
aléatoires »
présenté par Romain Azaïs

Marc Tommasi
Professeur en informatique
Université de Lille

3 novembre 2022

Dans ce manuscrit, Romain Azaïs a choisi de présenter ses activités de recherche dans deux thématiques générales, à savoir, *la statistique non paramétrique des processus markoviens déterministes par morceaux* et *les modèles statistiques sur des données arborescentes*. Dans les deux cas, le travail est bien dans le domaine des mathématiques appliquées. À chaque fois, la motivation d'étudier formellement les propriétés de modèles motivés par l'observation de systèmes physiques issus de processus naturels me semble une caractéristique déterminante pour Romain Azaïs. Aussi, cette motivation conduit-elle naturellement chez bon nombre de chercheurs, à la nécessité de ne pas oublier les aspects algorithmiques et la faisabilité en termes de complexité lorsqu'il s'agit de mesurer ou d'estimer ces propriétés. C'est donc aussi cette dimension algorithmique que Romain Azaïs place comme un élément unificateur de ses études guidées par les données de ces systèmes.

Le manuscrit de 79 pages est structuré en 4 chapitres suivant une courte introduction. Les deux premiers sont consacrés au premier thème et concernent l'estimation des taux de saut dans les processus markoviens déterministes par morceau (PDMP) et le second s'intéresse au croisement (le dépassement) de tels processus avec un seuil critique haut ou bas. Après ces deux chapitres aussi intitulés « *Le grand saut* », et « *À la croisée des chemins* », le chapitre 3, intitulé « *Bifurcation* », révèle aussi,

au delà du jeu rédactionnel, un changement de centre d'intérêt ou tout au moins une nouvelle ouverture pour les recherches de Romain Azaïs. Il introduit cette bifurcation vers l'étude des structures arborescentes. Ce chapitre 3 propose des noyaux basés sur les sous-arbres. La notion de similarité entre arbres et son évaluation sont bien évidemment au centre de nombreuses méthodes d'apprentissage machine sur ces types de données. Enfin le dernier chapitre étudie des processus génératifs d'arbres aléatoires et particulièrement deux conditionnements par la taille et la hauteur.

Mon domaine d'expertise se situant à la fois dans les données arborescentes et l'apprentissage machine, je concentre ce rapport sur les deux derniers chapitre de ce manuscrit. En effet, même si les deux premiers chapitres étudient des propriétés de convergence d'estimateurs sur des processus markoviens, très pertinents en apprentissage machine, les outils fondamentaux statistiques mis en œuvre ne font pas partie de mes compétences. Je tiens d'ailleurs à souligner l'effort de pédagogie évident réalisé par Romain Azaïs pour faire comprendre la thématique à un plus large public que les seuls experts en mathématiques appliquées. De façon plus générale, le manuscrit est remarquablement écrit, agréable à lire et éclairant.

Le chapitre 3 présente des travaux sur des données arborescentes que Romain Azaïs a débutés lors de son post-doctorat et dont la thématique reste très vivante dans ses activités actuelles. Partant de problèmes de compression, il a été amené à définir des noyaux de convolution pour des arbres qui évidemment se révèlent pertinents dans un cadre d'apprentissage machine pour données arborescentes. Ici les approches sont présentées sur des arbres non ordonnés mais semblent relativement indépendantes du type d'arbre, issus d'une Σ -algèbre ou d'un processus génératif moins contraignant (arbres ordonnés, non-ordonnés, d'arité bornée ou non, ...). Néanmoins, du point de vue algorithmique et de la complexité, le type d'arbre peut impacter les problèmes de décision comme l'isomorphisme et donc l'énumération et les calculs afférents utiles lors de l'estimation de modèles. Un deuxième choix d'impact majeur sur l'algorithmique et la complexité est le choix du type de noyau. Romain Azaïs présente dans ce chapitre des résultats pour des noyaux particuliers basés des statistiques de sous-arbres pour lesquels la complexité peut rester raisonnable. Une observation immédiate illustrant la sensibilité de Romain Azaïs aux questions algorithmiques et qui est formellement obtenue en section 3.3, est qu'un changement de représentation sous forme de graphe dirigé acyclique (DAG) permet un pré-processing rendant plus efficace le calcul de ces types de noyau.

Mais indépendamment du choix de représentation sous forme d'arbre ou de DAG, la similarité entre arbres est alors la somme pondérée des noyaux calculés sur ces nombres d'occurrences de sous-arbres. La question principale qui motive les premiers résultats du chapitre est la nature de cette pondération habituellement considérée

comme une forme exponentielle issue d'un calcul efficace récursif.

Ce caractère exponentiel choisi par de nombreux auteurs est discuté et remis en cause au travers d'un modèle génératif particulier d'arbres aléatoires permettant de générer une famille de problèmes de classification binaire. Dans ces problèmes, les deux classes comprendront des arbres les plus distincts possibles jusqu'à des arbres très similaires par substitution de sous-arbres, à des hauteurs plus ou moins grandes, par des arbres identiques. Le résultat théorique issu de ce modèle d'arbres aléatoires particulier, étant donné un noyau K , exhibe une borne supérieure en nombre d'exemples nécessaires à l'algorithme de classification basé sur K pour atteindre une erreur de classification donnée, dépendante des paramètres de la loi de tirage des hauteurs d'arbres. En corollaire, cette borne permet de constater que ce nombre d'exemples est minimal lorsque les poids des feuilles, seuls sous-arbres toujours communs entre deux arbres de classes différentes, dans le noyau sont nulles. Le constat ainsi établi donne l'idée d'une nouvelle fonction de poids qui tend à limiter le poids de sous-arbres communs à deux classes. Ou encore, dans sa généralisation aux problèmes multi-classes, la fonction de poids que propose Romain Azaïs, tend simplement à minimiser les poids des sous-arbres non discriminants. Toutefois, le caractère discriminant utilisé ici reste assez basique car essentiellement basé une indépendance des statistiques des sous-arbres. Mais fondamentalement, l'observation (et l'approche qui s'en déduit) est que la fonction poids est désormais dépendante des données et la contribution se rapproche alors des méthodes d'apprentissage de métriques. Cette partie se conclut par une évaluation empirique qui confirme la pertinence de cette pondération ne suivant pas une forme exponentielle ou plus précisément devant dépendre des données. Le chapitre se termine en exploitant les conclusions de cette première partie. Il s'agit ici d'étendre l'expressivité de la classe des méthodes à noyau en déterminant la fonction de poids à partir des données. Mais les sous-arbres ne sont plus pris indépendamment en leur attribuant un poids adapté, mais c'est en considérant des sous-forêts et une pondération (dépendante des données) sur celles-ci que le noyau devrait être calculé. Évidemment, cette approche relève du défi par la combinatoire qu'elle introduit et le premier problème consiste à évaluer les statistiques, donc revient à savoir réaliser efficacement l'énumération de ces sous-forêts. Sans un changement de représentation sous forme de DAG, celui-ci n'est pas envisageable et Romain Azaïs expose alors un résultat de complexité par le biais de l'arbre d'énumération des forêts non-redondantes à partir d'un DAG. Malgré tout, la complexité reste très importante et ne peut s'envisager qu'en limitant la profondeur de cet arbre.

Dans le chapitre 4, le sujet porte sur des problèmes d'estimation dans des modèles génératifs d'arbres aléatoires, les modèles de Galton-Watson. Les arbres sont ici ordonnés et Romain Azaïs étudie la loi de naissance qui est définie via la pro-

babilité $\mu(i)$ d'un nœud à avoir i enfants dans ce modèle aléatoire récursif. Deux conditionnements de cette loi de naissance sont considérés : par la hauteur et par la taille.

Dans le cas d'un conditionnement par la taille, i.e. on conditionne l'arbre aléatoire à avoir n nœuds, Romain Azaïs montre que la variance empirique du nombre d'enfants (d'un unique arbre observé) tend vers la variance de la loi de naissance quand n tend vers l'infini. Ce résultat bien que simple en apparence et peut-être peu surprenant, repose sur une preuve technique non triviale. Il conclut également une tentative sans doute plus originale d'étudier ces arbres aléatoires conditionnés par la taille via une représentation sous la forme d'une fonctionnelle reposant sur un parcours de l'arbre de gauche à droite et en profondeur d'abord (la marche de Harris). En effet sa convergence vers un mouvement brownien revenant à son origine laissait l'espoir d'une autre approche pour l'estimation de cette variance, mais Romain Azaïs démontre également que cette estimation ne peut se faire sans biais quand n tend vers l'infini, à partir d'un seul arbre.

Dans le cas d'un conditionnement par la hauteur, c'est-à-dire à avoir une hauteur au moins égale à h , on s'intéresse plus particulièrement à des arbres à épine dorsale. Plus précisément, la loi de naissance est de moyenne inférieure à 1 (le nombre de moyen de noeuds devrait être fini) mais certains noeuds sont d'un autre type et biaisés pour satisfaire ce conditionnement. La probabilité $\mu(i)$ d'avoir i enfants pour les nœuds de type « normal » est alors multipliée par un facteur $f(i)$ pour ces noeuds d'un autre type. L'estimation de ce modèle passe alors par la maximisation en μ de la vraisemblance d'une observation d'un tel arbre. Les nœuds sur l'épine dorsale, sont alors identifiés comme appartenant à la lignée la plus divergente par rapport aux lignées soumises à la loi de naissance « normale ». En conséquence, Romain Azaïs est alors capable de corriger l'estimateur de μ et d'estimer f .

Le travail présenté par Romain Azaïs est original et remarquable. Ce manuscrit, offre une synthèse d'une très grande qualité rédactionnelle de 26 publications, en articles de conférence, journaux ou pré-publications. Certaines publications ont paru dans des journaux renommés en statistiques comme TEST, en apprentissage machine comme JMLR, ou en informatique théorique comme TCS. Cette variété de sujets et de centres d'intérêt est une des remarquables qualités de Romain Azaïs. L'ensemble de ce manuscrit pose des questions et apporte des réponses éclairantes dans ces différents domaines. Les preuves (non présentées par souci de pédagogie et esprit de synthèse), techniques et difficiles, les développements logiciels, les domaines d'application, les collaborations illustrent ce large spectre de compétences de Romain Azaïs et posent selon moi une excellente base pour une activité de direction de recherche. Celle-ci s'est déjà confirmée par l'encadrement de doctorant. Pour toutes ces raisons,

je donne un avis très favorable pour la soutenance de Romain Azaïs pour l'obtention de l'habilitation à diriger des recherches.

Marc Tommasi
Villeneuve d'ascq le 3 novembre 2022

A handwritten signature in black ink, consisting of a large, stylized 'M' followed by a horizontal line and a small dot.